



基于图卷积神经网络的射频功放数字预失真模型

马施榆 解程杰(宁波大学信息科学与工程学院 浙江 宁波 315211)

摘要: 本文提出了一种基于图卷积神经网络的射频功放数字预失真模型,可以有效地对宽带射频功放进行非线性补偿。通过时序处理模块和 LSTM 层提取输入数据中的时域特征;同时对经过时序处理模块后的输入数据进行相关性分析等操作,并通过图卷积层提取数据的频域特征,最后通过全连接层得到最后的预失真信号。为了验证该方法的有效性,使用 60MHz 带宽的 5G NR 信号对中心频率 1.9GHz 的 50W Doherty 功放进行预失真线性化测试。预失真非线性建模的归一化均方误差(NMSE)可达到 -35dB,实验结果表明经过基于图卷积神经网络的数字预失真模型的功放与没有经过预失真模型的功放相比,邻信道泄漏比(ACLR)改善超过 15dB,同时带内的 3dB 失真也得到了有效改善,验证了所提出非线性模型的有效性。

关键词: 5G; 功率放大器; 数字预失真; 图卷积

0 引言

射频发射机的线性化是现代无线通信系统中最重要问题之一。在无线通信射频发射机中,功率放大器是主要的能源消耗来源,也是主要的记忆效应和非线性的来源。目前,为了补偿功率放大器的非线性,从而提高发射机的通信质量和减少能源消耗,提出了许多线性化技术,如功率回退、前馈、模拟预失真和数字预失真。其中数字预失真实现比较简单,因其成本低、易实现、性能好的优势成为了应用最广泛的功放线性化技术。数字预失真技术是处理基带信号,使用一个非线性模块来补偿功放的非线性,从而实现输出的线性化。现有许多 DPD 模型,由开始的 Volterra 级数^[1]改进形成了记忆多项式(MP)模型^[2]以及广义记忆多项式(GMP)模型^[3],这些模型都由一组基函数形成,基函数考虑了 PA 的记忆效应。

与传统的 DPD 模型相比,神经网络凭借其强大的拟合能力被广泛应用于数字预失真领域^[4]。在神经网络多层感知机的基础上,文献[4]提出了实值时延神经网络(RVTDNN)模型,用同相正交分量(I/Q)

替代复数基带信号,并用于训练神经网络,避免了复数训练时复数梯度计算困难的问题。为了提高模型的性能,文献[5][6]在输入层添加了更多的分量,文献[5]在输入层除了加入当前时刻的 I/Q 分量还加入了之前时刻的 I/Q 分量;文献[6]在输入层另外加入了信号的包络项。虽然增加输入项可以使模型的性能得到提升,但同时也增加了模型的复杂度,文献[7]提出了残差实值时延神经网络(R2TDNN)模型,R2TDNN 在模型的计算复杂度较低或相近的基础上拥有更低的训练误差和更高快的训练速度。除了多层感知机,长短时记忆(LSTM)网络在针对数字预失真的研究上也作出了巨大贡献^[8-10],利用 LSTM 单元内部的传递机制去拟合功放内部复杂的记忆效应。通常对预失真模型的搭建只考虑时域上的关联性,未能充分考虑频域上的相关性,因此建模不够充分。

基于上述分析,本文针对这个问题提出了基于图卷积神经网络的射频功放数字预失真模型。本文将讨论单层图卷积层的工作原理和图卷积神经网络中的逐层

传递机制,由此构建了基于图卷积神经网络的射频功放数字预失真模型;描述了预失真验证的实验平台,并给出了最终的实验结果;最后对实验结果进行了分析。

1 图卷积神经网络数字预失真模型

1.1 图卷积神经网络

图卷积层的实质是图信号与图卷积核相乘^[11],如式(1)所示:

$$g_{\theta} *_{\mathcal{G}} x = U g_{\theta} U^T x \quad (1)$$

其中, g_{θ} 为图卷积核, $*_{\mathcal{G}}$ 表示图卷积运算, x 表示输入的数据, U 表示特征向量矩阵。

神经网络的归一化拉普拉斯矩阵^[11]如式(2)所示:

$$L = I_N - D^{-\frac{1}{2}} A D^{-\frac{1}{2}} = U \Lambda U^T \quad (2)$$

I_N 表示单位矩阵, A 表示由特征值构成的对角矩阵, A 表示神经网络中节点的邻接矩阵, D 表示节点的度矩阵,其中:

$$D_{ii} = \sum_j A_{ij} \quad (3)$$

对于大型图来说,节点数目众多, L 对进行特征分解有着巨大的计算复杂度。为了规避这个问题,2011年 Hammond 等人提出可以用 K 阶切比雪夫多项式 $T_k(x)$ 来逼近图卷积核 $g_{\theta}(\Lambda)$ ^[12],即:

$$g_{\theta}(\Lambda) \approx \sum_{k=0}^K \theta'_k T_k(\tilde{L}) \quad (4)$$

$\theta' \in \mathbb{R}^K$ 表示由切比雪夫系数组成的向量,同时 \tilde{L} 可以表示为式(5):

$$\tilde{L} = \frac{2}{\lambda_{\max}} L - I_N \quad (5)$$

其中 λ_{\max} 表示拉普拉斯矩阵中最大的特征值。对于切比雪夫多项式 $T_k(x)$ 满足^[11]:

$$\begin{aligned} T_0(x) &= 1 \\ T_1(x) &= x \\ &\vdots \\ T_k(x) &= 2x T_{k-1}(x) - T_{k-2}(x) \end{aligned} \quad (6)$$

基于上述信息,将单层图卷积拓展到多层图卷积神经网络中。基于多层图卷积的神经网络逐层传递机制^[11]满足:

$$H^{(l+1)} = \sigma \left(\sum_{k=0}^K \theta'_k T_k(\tilde{L}) H^{(l)} \right) \quad (7)$$

其中激活函数 σ 定义为 $\text{ReLU}(\cdot) = \max(0, \cdot)$ 。

1.2 模型搭建

基于图卷积神经网络的功放数字预失真模型结构如图1所示。

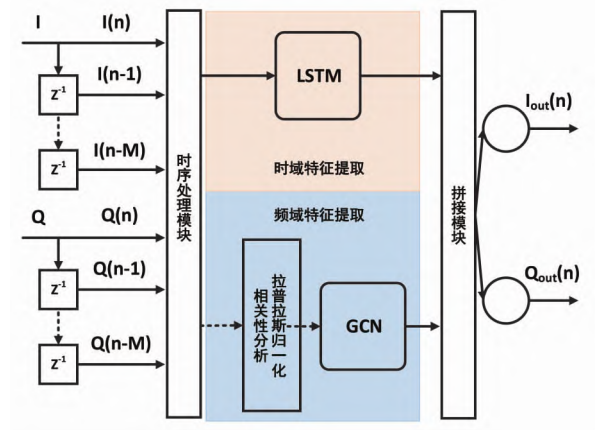


图1 基于图卷积神经网络的功放数字预失真模型结构

该网络结构一共分为六个模块:输入模块、时序处理模块、时域特征提取模块、频域特征提取模块、拼接模块和输出模块。具有 M 阶记忆深度的 I/Q 两路数据为:

$$\begin{aligned} &[I(n), I(n-1), \dots, I(n-M), \\ &Q(n), Q(n-1), \dots, Q(n-M)]^T \end{aligned} \quad (8)$$

由于 LSTM 神经元特有的遗忘门、输入门、输出门的概念,其当前时刻的输出不仅依赖当前时刻的输入,还依赖之前时间步神经元的状态和输出。因此需要用时序处理模块将具有 M 阶记忆深度的 I/Q 数据处理成符合 LSTM 层训练规则的时间序列,时间序列形式如下所示:

$$\begin{bmatrix} I(n) & Q(n) \cdots & I(n-M) & Q(n-M) \\ I(n-1) & Q(n-1) \cdots & I(n-1-M) & Q(n-1-M) \\ \vdots & \vdots & \vdots & \vdots \\ I(n-T) & Q(n-T) & I(n-T-M) & Q(n-T-M) \end{bmatrix} \quad (9)$$

时间序列按照时刻的先后顺序依次通过后面的 LSTM 层,其中时间序列的第一行相较于时间序列的最后一行滞后 T 个时间步。LSTM 神经元相比 RNN 神经元增加了遗忘门、输入门、输出门三个决策门,克服了传统循环神经网络中梯度消失和梯度爆炸的问题。同时 LSTM 神经元增加了状态 C_t ,其控制之前时刻的信息对当前时刻的影响程度。经过 T 个时间步, LSTM 神经元得到最终的输出。时间序列通过 LSTM 层之后得到含有 G 个神经元的 LSTM 层的输出:

$$O(n) = [o_1(n), o_2(n), \dots, o_G(n)]^T \quad (10)$$

同时时间序列通过相关性分析和拉普拉斯归一化得到对应的特征序列 X 和邻接序列 A 。对应的序列 $\chi = [X, A]$ 传入图卷积层,并通过前文提到的逐层传递机制得到频域特征模块的输出:

$$Z = \text{ReLU}(g_{\theta} * c\chi) \quad (11)$$

紧接着将时域特征和频域特征进行水平拼接,得到融合了关键性信息的特征向量:

$$v = \text{Concat}(O, Z) \quad (12)$$

最后, v 被送入输出模块,得到模型的最终输出 $[I_{out}(n), Q_{out}(n)]$,以上为模型的整体架构。

2 实验验证及结果分析

2.1 实验平台

为了验证图卷积神经网络预失真模型的有效性,搭建了如图2所示的数字预失真测试平台。实验采用了60MHz的5GNR信号作为测试信号,中心频率为1.9GHz输出功率为50W的LDMOS Doherty射频功率放大器,40dB衰减器,德国罗德施瓦茨SMW200A矢量信号发生器和FSW85频谱分析仪。数据采集时采用频谱分析仪,以200Msps的采样率采集了功放的输入输出信号,然后利用神经网络构建功放的逆模型对功放进行预失真处理,再通过实验平台验证其预失真效果。

在训练模型时,将采集到的功放的实际输出作为模型的输入,将功放的实际输入作为目标值,利用误差反向传递梯度下降使得模型参数得到优化,最后利用归一化均方误差(NMSE)来衡量模型对目标值的拟合程度,NMSE的数值大小与拟合程度成反比,NMSE的数值越小,说明模型的拟合程度越高。NMSE的计算公式如下:

$$\text{NMSE} = 10 \lg \frac{\sum_{n=1}^N |y_{\text{target}}(n) - y_{\text{model}}(n)|^2}{\sum_{n=1}^N |y_{\text{target}}(n)|^2} \quad (13)$$

其中, y_{target} 表示实际采集到的功放的输入信号, y_{model} 表示模型预测的输出值。在网络模型收敛之后,基于图卷积神经网络的预失真模型 NMSE 达到 -35dB,说明该网络对功放逆模型有较好的非线性拟合能力。

2.2 数字预失真线性化能力验证及分析

图3表现了无预失真和经过预失真处理后功放自身的非线性特性。根据 AM/AM 图,射频功放在输入功率增大时有大约 5dB 的增益压缩。经过预失真之




图2 预失真实验验证平台

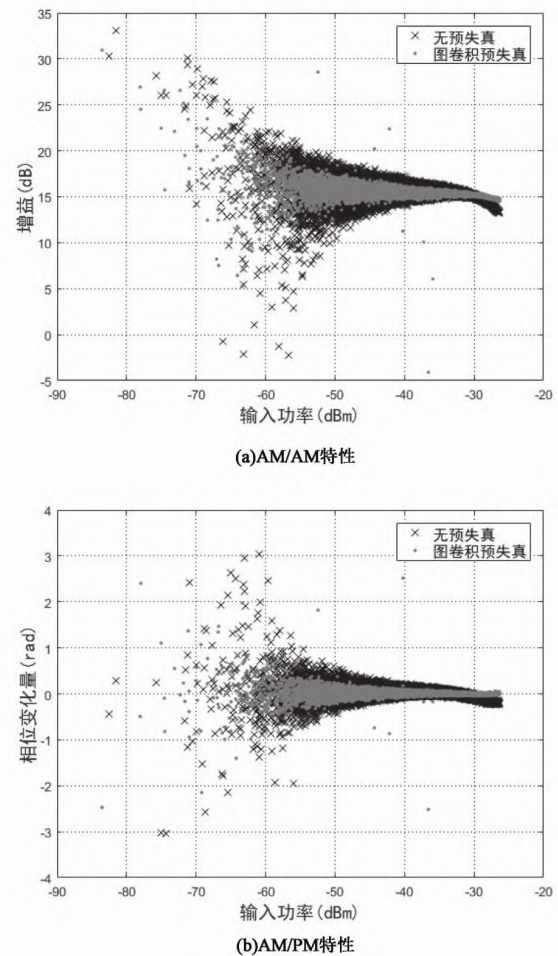


图3 1.9GHz 射频功放非线性特性

后,功放的非线性和记忆效应得到了有效地抑制。可以明显看到功放的 AM/AM 特性图和 AM/PM 图基本上呈现线性,而且原本发散性得到一定收敛。

利用图2所示实验平台,将图卷积预失真模型得到的预失真信号送入矢量信号发生器,并通过信号发



生器上变频到 1.9GHz 后输入到射频功放,功放的输出端连接衰减器,信号经过衰减器传输给频谱仪,最后通过频谱仪观察预失真模型的线性化效果。




图 4 1.9GHz 功率谱密度对比图

如图 4 所示,图卷积预失真模型在中心频率为 1.9GHz 的功放上呈现良好的线性化效果。可以看出在经过预失真之后,ACLR 的改善超过 15dB,改善效果明显。同时带内的倾斜也得到了补偿,原本带内左边比右边高出 3dB,经过预失真之后的功放完全消除了带内的倾斜。所以基于图卷积神经网络的功放数字预失真模型可以给功放的非线性带来良好的补偿效果。

3 结论

本文提出了一种基于图卷积神经网络的射频功放数字预失真模型。通过时序处理模块和 LSTM 层提取输入数据中的时域特征;同时将时序处理模块的输出进行相关性分析等操作,并通过图卷积层提取数据的频域特征,最后通过全连接层得到最后的预测值。本文采用 60MHz 带宽的 5G NR 信号对训练后的神经网络进行线性化测试,测试结果表明,经过基于图卷积神经网络的数字预失真模型的功放与未经过预失真模型的功放相比,邻信道泄漏比(ACLR) 改善超过 15dB,带内 3dB 左右的倾斜得到完全消除。通过上述实验证明,该预失真模型不仅改善了功放带外的三阶交调失真,对带内的不平也有很好的改善效果。

参考文献

- [1] EUN C, POWERS E J. A new Volterra predistorter based on the indirect learning architecture [J]. IEEE Trans. Signal Process., 1997, 45(1): 223 – 227
- [2] LEI D, ZHOU G T, MORGAN D R, *et al.* A robust digital baseband predistorter constructed using memory polynomials [J]. IEEE Trans. Commun., 2004, 52(1): 159 – 165
- [3] MORGAN D R, MA Z, KIM J, *et al.* A Generalized Memory Polynomial Model for Digital Predistortion of RF Power Amplifiers [J]. IEEE Trans. Signal Process., 2006, 54(10): 3852 – 3860
- [4] LIU T, BOUMAIZA S, GHANNOUCHI F M. Dynamic Behavioral Modeling of 3G Power Amplifiers Using Real – Valued Time – Delay Neural Networks [J]. IEEE Trans. Microw. Theory Tech., 2004, 52(3): 1025 – 1033
- [5] MKADEM F, BOUMAIZA S. Physically Inspired Neural Network Model for RF Power Amplifier Behavioral Modeling and Digital Predistortion," IEEE Trans. Microw. Theory Tech., 2011, 59(4): 913 – 923
- [6] WANG D, AZIZ M, HELAOUI M, *et al.* Augmented Real – Valued Time – Delay Neural Network for Compensation of Distortions and Impairments in Wireless Transmitters [J]. IEEE Trans. Neural Netw. Learn. Syst., 2019, 30(1): 242 – 254
- [7] WU Y, GUSTAVSSON U, I AMAT A G, *et al.* Residual Neural Networks for Digital Predistortion [J]. in GLOBECOM 2020 – 2020 IEEE Global Communications Conference, 2020: 1 – 6
- [8] PHARTIYAL D, RAWAT M. LSTM – Deep Neural Networks based Predistortion Linearizer for High Power Amplifiers [J]. in 2019 National Conference on Communications (NCC), 2019: 1 – 5
- [9] LIU T, YE Y, YIN S, *et al.* Digital Predistortion Linearization with Deep Neural Networks for 5G Power Amplifiers [J]. in 2019 European Microwave Conference in Central Europe (EuMCE), 2019: 216 – 219
- [10] LI H, ZHANG Y, LI G. Vector Decomposed Long Short – Term Memory Model for Behavioral Modeling and Digital Predistortion for Wideband RF Power Amplifiers [J]. IEEE Access, 2020, 8: 63780 – 63789
- [11] KIPF T N, WELING M. Semi – Supervised Classification with Graph Convolutional Networks [J]. arXiv: 1609. 02907 [cs, stat], Feb. 2017, Accessed: Apr. 02, 2022. [Online].
- [12] HAMMOND D K, VANDERGHEYNST P, GRIBONVAL R. Wavelets on graphs via spectral graph theory [J]. Applied and Computational Harmonic Analysis, 2011, 30(2): 129 – 150

作者简介: 马施榆(1997 –), 女, 硕士生, 主要研究方向为功率放大器非线性建模、线性化技术和深度学习。■