



基于神经网络的数字预失真模型验证

舒海燕 许高明(宁波大学信息科学与工程学院 浙江 宁波 315211)

摘 要: 功放的非线性会导致信号的失真和频谱再生, 因此数字预失真被认为是解决功放非线性的一种方法, 但是由于信号的带宽越来越宽, 且系统越来越复杂, 这些传统的预失真方法已经无法满足需要, 因此神经网络开始被应用于数字预失真。本文对 LSTM、GRU、BiGRU 网络建立数字预失真平台, 使用 1.9GHz 的功放对 5G-NR 信号进行实验。实验结果表明: LSTM、GRU、BiGRU 这三个模型都可以应用于线性化, 并且 ACLR 最高可达 17dB, 因此这三个模型均可用于功放的非线性改善。

关键词: 数字预失真; LSTM; GRU; BiGRU

中图分类号: TP391 **文献标识码:** A

0 引言

随着科学技术的发展, 无线通信行业也在不断革新和突破。功率放大器作为无线通信系统中一个很重要的部件, 它的主要原理是将输入信号进行处理的电子设备, 随后功放通过天线把信号发射到外面, 然而功放的信号会产生失真, 即信号的输入输出呈现非线性的关系, 功放的非线性带来的问题也随之产生。功放的非线性会干扰工作频带内的信号, 也会产生频带再生, 使得相邻信道的传输质量大大减少。随着功放带宽的要求越来越高, 功放的非线性要求也越来越高, 因此功放的非线性必须进行改善。

数字预失真技术被认为是解决功放非线性问题的一个常见的方法。主要原理是利用数学工具对功放行为特性进行建模, 将预失真的特性设置为和功放特性恰好相反的特性, 然后将两者进行级联从而降低非线性。数字预失真技术对功放的非线性行为进行建模, 由于带宽的不断变宽和更高的调制信号被提出来, 这些传统的行为模型已经不能用来作为实验需要。神经网络近年来被提出用于解决功放线性化问题。1996 年文献[1]提出了神经网络自适应预失真技术; 2014 年

文献[10]提出了一种基于前馈抽头延迟线的神经网络; 2022 年文献[12]提出了改进的 CNN 网络应用于数字预失真。

本文对 LSTM、GRU、BiGRU 的神经网络进行功放建模, 建立数字预失真平台, 对三种不同的网络进行性能比较, 验证了线性化效果。

1 神经网络原理

1.1 LSTM 原理

LSTM 模型是由 RNN 变换而来, 在传统的 RNN 网络中, 输入为数据本身, 数列在前进的方式上为递归, 所有的神经元按照链式进行连接, 目的就是为了让历史信息 and 当前信息能共同作用到网络中去, 从而确保 RNN 能够对时间序列进行处理, 并且这样做具有很大的优势。LSTM 比一般的神经网络多一个反馈的输入信息, 将上一次的神经元的计算结果运用到新的神经元上去。

RNN 神经网络结构和人类的大脑有着很强的相似性, 当输入历史信息, 计算和分析获得预测结果。因为 RNN 存储历史信息存在一定的限制, 早期

的历史信息可能会没有办法保留,但是对相邻时刻的信息能够有较大的保留。此外,由于训练的重复性,可能会导致出现衰减现象,因此 RNN 可能会存在梯度消失问题,LSTM 网络通过不断地累积来把历史信息记录下来,这样很久之前的历史信息都被保存进去,因此,只是改变了 RNN 的结构就使得以前的历史信息保存下来。LSTM 主要包括三个门,分别为遗忘门、输入门、输出门。LSTM 内部的结构如图 1 所示:




图 1 LSTM 原理图

其中, σ 表示激活函数,激活函数一般是 sigmoid,生成 0 到 1 之间的数据, z^f, z^i, z^o 是 LSTM 的三种门控状态, z 表示 LSTM 输入数据。LSTM 内部的计算过程主要分为三个阶段,第一个阶段是遗忘门的处理,遗忘门将上一时刻的隐藏状态 h_{t-1} 与当前时刻的数据 x_t 共同输入到 sigmoid 函数。如公式 (2) 最后的 z^f 是一个介于 0 到 1 之间的值,其中越接近 0 越应该被遗忘,越接近 1 则应该被记住。当 z^f 为 0 的时候,表示前面的信息全部被遗忘,当 z^f 为 1 的时候,前面的信息全都记住。这一部分主要是为了对输入数据 x_t 进行有选择的遗忘。

$$z^f = \sigma(w_{hf} h_{t-1} + w_{xf} x_t + b_f) \quad (1)$$

x_t 为当前时刻的输入, h_{t-1} 为上一时刻的隐藏状态, z^f 表示遗忘门的输出, w_{hf} 表示上一时刻的隐藏状态到遗忘门的权重, w_{xf} 表示输入到遗忘门的权重, b_f 为偏置。

第二个阶段是输入门 z^i 的处理,通过输入门对输入数据 x_t 进行有选择的记忆,第一步也是生成一个 0 到 1 之间的值,第二步是利用 tanh 函数,得到候选单元状态 z 。

$$z^i = \sigma(w_{hi} h_{t-1} + w_{xi} x_t + b_i) \quad (2)$$

$$z = \tanh(w_{hz} h_{t-1} + w_{xz} x_t + b_z) \quad (3)$$

x_t 为当前时刻的输入, h_{t-1} 为上一时刻的隐藏状态, w_{hi} 表示上一时刻的隐藏状态到输入门的权重, w_{xi} 表示输入到输入门的权重, b_i 为偏置, w_{hz} 表示上一时刻的隐藏状态到当前输入单元的状态权重, w_{xz} 表示当前输入到输入单元的状态的权重, z^i 表示输入门的输出, z 表示候选单元的状态。

然后由公式 (4) 更新单元状态,将旧的单元状态 c_{t-1} 更新为 c_t ,实现方法就是通过遗忘门遗忘一部分信息,通过输入门将 z 的信息添加到新的单元信息。

$$c_t = z^f \times c_{t-1} + z^i \times z \quad (4)$$

第三个阶段是对输出门的处理,通过输入的 h_{t-1} 和 x_t 来判断输出细胞的哪些状态特征,首先将输入经过一个输出门,得到 sigmoid 值,然后将单元状态 c_t 经过 tanh 得到一个向量,再将该向量和输出门得到的输出相乘得到了当前状态的输出 h_t ,最终的输出 y_t 由 h_t 变换而来。

$$z^o = \sigma(w_{ho} h_{t-1} + w_{xo} x_t + b_o) \quad (5)$$

$$h_t = z^o \times \tanh(c_t) \quad (6)$$

$$y_t = \sigma(w' h_t) \quad (7)$$

功放的记忆效应会使得信号产生失真,记忆效应使得功放的输出和当前输入有关,和以前信号也有关系,为了更好地表示信号的记忆效应对于输出的影响,LSTM 网络的遗忘门对上一时刻的状态有选择地遗忘,输入门对当前节点的输入有选择地记忆。

1.2 GRU 原理

为了更好地解决 RNN 的梯度消失和梯度爆炸问题,GRU 被提出来,GRU 主要通过门控单元来存储信息,GRU 同样有多个单元,但是 GRU 只有两个门控单元,比 LSTM 更为简单,GRU 内部的计算复杂度也要低于 LSTM。GRU 通过 sigmoid 函数将上一个时刻和当前时刻的信息拼接后形成一个限制,实现长序列信心的传递,GRU 的变量只有两个,分别是上一时刻的隐藏状态和当前时刻输入。在门控机制上,GRU 仅仅通过更新门和重置门就实现了和 LSTM 一样的效果,内部的训练参数变少,提高了训练的速度,节约硬件资源。

更新门 z_t :

x_t 为第 t 个时刻的输入变量,它会经过一个线性变换, h_{t-1} 保存的是前一个时刻的信息,它相同的也需要经过一次线性变换,更新门将这两部分的信息相加并投入到 sigmoid 函数中去。

$$z_t = \sigma(W_z \times [h_{t-1} \ x_t]) \quad (8)$$

重置门 r_t :

控制前一时刻的状态有多少历史信息被写入到候选集 h_{t-1} 上,重置门如果很小,说明很多历史信息没有被写进去,同更新门处理数据一样,将前一时刻和当前时刻的信息分别右乘权重矩阵,然后将相加后的数据送入重置门。

$$r_t = \sigma(W_r \times [h_{t-1} \ x_t]) \quad (9)$$

关于重置门如何影响最终输出,主要是通过一个 \tanh 函数,新的记忆内容将使用重置门储存过去相关的信息。

$$h'_t = \tanh(W_h \times [r_t \times h_{t-1} \ x_t]) \quad (10)$$

最终输出,为了得到 h_t ,需要使用更新门,用来决定当前的记忆内容 h'_t 和前一段时间 h_{t-1} 中需要的信息有哪些,可以表示为:

$$h_t = (1 - z_t) \times h_{t-1} + z_t \times h'_t \quad (11)$$

GRU 的原理图如图 2 所示,GRU 是 LSTM 的简化,并且 LSTM 和 GRU 的效果大致相似,GRU 结构比较简单,因此也可以运用在实际工作中。由于参数的占用空间更小,因此它的拟合效果比 LSTM 更好一些。

LSTM 利用遗忘门对功放的记忆效应进行补偿,使用输入门对网络状态进行更新,更新后保存到当前状态量,而在 GRU 中直接用更新门就可以完成对记忆效应的模拟。




图2 GRU 原理图

1.3 BiGRU 原理

LSTM、GRU 所构建的预失真器为因果性的系统,即当前时刻的输出不仅取决于当前时刻的输入,同时取决于以前时刻的输入。然而在实际应用中,如果能够获取序列的整个信息,就能取得更好的效果。BiGRU 神经网络模型不仅能够获取之前时刻的输入,未来时刻的输入也可以进行处理,使得网络的拟合效果更好。

BiGRU 有两个隐藏层,这两个隐藏层的内部结构

是相同的,但是方向却是相反的,依靠两个方向为网络提供数据。正向的 GRU 计算数据的正向传播信息,反向的 GRU 反向读取数据信息,这两层 GRU 在计算的时候互不干扰。图 3 是一个典型的原理图,包含一个正向的 GRU,一个反向的 GRU,将一个完整的序列输入到 BiGRU 中去,正向 GRU 状态进行正向输出,反向 GRU 进行反向输出,每一个时刻都有一个损失函数接受正向 GRU 和反向 GRU 的结果,再结合两个预测输出,最终得到 BiGRU 的输出。




图3 BiGRU 原理图

为了验证 LSTM、GRU、BiGRU 预失真器模型的线性化效果,搭建了如图 4 所示的预失真的实验平台,平台由 R&S 的矢量信号发生器(SMW-200A)、频谱分析仪(FSW)、1.9GHz 功放、衰减器组成。使用 5G NR 信号,信号带宽为 20MHz。进行预失真实验时,先将信号下载到信号发生器中,然后接入功放,功放再经过衰减,利用频谱仪观察输出信号的频谱。为了保证信号采集数据的准确性,需要将时间同步和触发同步,时钟同步主要是将信号发生器的参考频率输出给频谱分析仪 FSW,触发同步主要是将矢量信号发生器的 user1 连接到 FSW 的外部触发。采集数据主要是通过 FSW 内部的 I/Q analyzer 调整采样带宽和采样点数,切换到时域状态,保存数据,最后得到 I/Q 两路采样信号。为了更好地说明拟合效果,使用归一化均方误差(NMSE)来衡量建模精度,NMSE 越小,表示建模精度越高,NMSE 的计算公式如下:

$$NMSE = 10 \lg \frac{\sum_{n=1}^N |y_{\text{meas}}(n) - y_{\text{model}}(n)|^2}{\sum_{n=1}^N |y_{\text{meas}}(n)|^2} \quad (12)$$

$y_{\text{meas}}(n)$ 为功放的输出数据, $y_{\text{model}}(n)$ 为拟合的输出值。

2 数字预失真结果

将原始的信号通过建立预失真模型,生成预失真

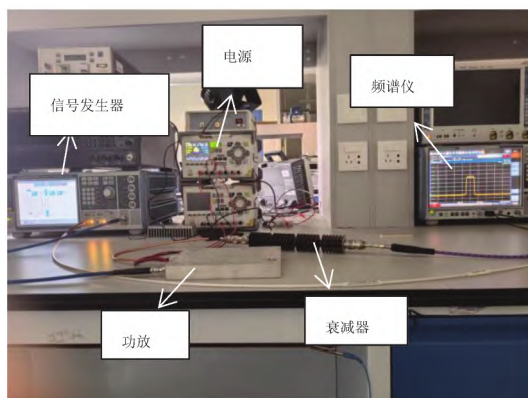


图4 预失真平台

信号,然后把预失真信号加载到信号发生器上,经过功放产生输出,再把输出结果放到频谱仪上,通过频谱仪观察预失真的效果,可以看到 LSTM、GRU、BiGRU 预失真器的线性化性能比较,表1表示不同的单元数下功放 NMSE,可以看到对于单元数为 32 的时候,LSTM、GRU、BiGRU 预失真器的 NMSE 都是最大的,当 GRU、LSTM、BiGR 预失真器的单元数为 128 时,NMSE 为最小值。为了更好地表示记忆效应的影响,通过改变记忆深度实现对结果的改变。从图5可以看出随着记忆深度的增加,模型的线性化效果并未线性相关。可得 LSTM 预失真器的 NMSE 在记忆深度为 5 之前随着记忆深度的增加一直在减少,为 5 的时候出现拐点;5 到 8 之间时,NMSE 随着记忆深度的增加一直在减少;在 8 的时候出现了第二个拐点,此后 NMSE 在变大。GRU 预失真器的 NMSE 在记忆深度为 5 之前随着记忆深度的增加一直在减少;为 5 的时候出现拐点;在 6 的时候出现了第二个拐点,此后 NMSE 在变大;8 的时候出现了第三个拐点;8 之后 NMSE 随着记忆深度的增加在减小。BiGRU 预失真器的 NMSE 在 3 的时候出现第一个拐点,此后一直在增大,直到出现第二个拐点 5,在 5 之后总体的趋势在下降。

表1 不同神经网络单元下的 NMSE

单元数	LSTM	GRU	BiGRU
32	-35.88	-35.97	-37.72
64	-37.57	-40.02	-40.39
128	-39.62	-40.18	-39.842

通过频谱仪记录的 ACLR 值(图6)可以看出模型的线性化效果,可以看到 LSTM 的线性化效果最差,BiGRU 的线性化效果最好。LSTM 的左右边带下降大




图5 不同记忆深度下的 NMSE

约 15dB, BiGRU 的左右边带下降大约 17dB(表2)。




图6 预失真频谱图

表2 ACLR 改善值

模型	GRU	BiGRU	LSTM
左边带	-17.7858	-17.3812	-14.843
右边带	-16.1488	-17.5467	-14.4567

3 结束语

本文对 1.9GHz 的功放分别使用了 LSTM、GRU、BiGRU 模型对功放建立了行为模型,并且搭建了数字预失真平台,验证数字预失真效果。实验表明,这三个模型对功放的非线性都有改善效果,ACLR 最高可达 17dB,因此这三个模型可以应用于功放线性化。

(下转第 46 页)



4 结束语

本文探讨了5G网络的部署模式和用户面对报文转发性能的要求,并实践了DPDK技术和VPP技术,实现了较好的转发性能,证明这两项技术可以促进5G网络更好地服务于各行业。随着5G网络在各垂直行业进一步深入部署,边缘计算的MEC、定制化的承载网络设备以及各种行业应用网关等,对网络性能有较高要求的设备也可以参考5G网络的方式,应用这两项技术以实现更好的转发性能。

参考文献

- [1] 黄颖,于青民,李宗祥,等. 5G在工业互联网领域的应用进展[J]. 移动通信, 2022, 46(1): 41-45
 - [2] 黄珊. 5G关键技术及行业应用探索[J]. 数字通信世界, 2022(2): 30-32+35
 - [3] 范华敏. 5G时代行业专网的发展[J]. 邮电设计技术, 2022(2): 77-80
 - [4] 杨芳,徐明伟,陈浩. 5G/后5G部署对互联网主干影响的分析与建模[J]. 通信学报, 2019, 40(8): 36-44
 - [5] 张燕. 5G核心网虚拟化云资源池部署探讨[J]. 移动通信, 2019, 43(6): 10-15
 - [6] 3GPP TS23.501 System Architecture for the 5G System; Stage 2 [17.3.0] [S]. 2021
 - [7] 曾理,叶晓舟,王玲芳. DPDK技术应用研究综述[J]. 网络新媒体技术, 2020, 9(2): 1-8
 - [8] 张宇巍,曾一,杨燕宁. 基于VPP的虚拟路由器数据平面加速方法[J]. 计算机系统应用, 2017, 26(10): 276-280
 - [9] 潘恬,林兴晨,张娇,等. 基于高性能包处理架构VPP的带内网络遥测系统[J]. 通信学报, 2021, 42(3): 75-90
- 作者简介: 朱宜斌,硕士研究生,中兴通讯股份有限公司工程师,主要从事电信云、移动核心网等方面的研发。■

(上接第42页)

参考文献

- [1] 刘昕,陈文华,吴汇波,等. 功放数字预失真线性化技术发展趋势与挑战[J]. 中国科学: 信息科学, 2022, 52(04): 569-595
 - [2] 马施榆,解程杰. 基于图卷积神经网络的射频功放数字预失真模型[J]. 数据通信, 2022(06): 12-15
 - [3] 方俊. 基于增强型LSTM神经网络的5G射频功放线性化[J]. 无线通信技术, 2022, 31(02): 23-26
 - [4] 杨宦. 基于Attention循环神经网络的功放数字预失真研究[D]. 电子科技大学, 2022. DOI: 10.27005/d.cnki.gdzku.2022.004252
 - [5] 刘春秀,李军,许高明,等. 数字预失真器对5G功放记忆效应补偿能力的比较[J]. 数据通信, 2022(01): 9-13
 - [6] 苗德华,解程杰. 5G宽带功放线性化平台开发与验证[J]. 无线通信技术, 2022, 31(01): 6-10
 - [7] 周俊宇,许高明,韩栋,等. 基于数/模混合预失真技术的功放线性化[J]. 微波学报, 2022, 38(02): 91-94. DOI: 10.14183/j.cnki.1005-6122.202202019
 - [8] 张强. 5G宽带功放的数字预失真技术研究[D]. 东南大学, 2021. DOI: 10.27014/d.cnki.gdnau.2021.000453
 - [9] 廖晓. 面向5G无线通信系统数字预失真设计与实现[D]. 湖南大学, 2021. DOI: 10.27135/d.cnki.ghudu.2021.002844
 - [10] GOTTHANST, BAUDOUIN G, MBAYE A. Digital predistortion with advance/delay neural network and comparison with Volterra derived models [J]. 2014 IEEE 25th Annual International Symposium on Personal, Indoor, and Mobile Radio Communication (PIMRC), Washington, DC, USA, 2014: 811-815. doi: 10.1109/PIMRC.2014.7136276
 - [11] WATKINSB E, NORTH R. Predistortion of nonlinear amplifiers using neural networks [J]. Proceedings of MILCOM'96 IEEE Military Communications Conference, McLean, VA, USA, 1996, 1: 316-320. doi: 10.1109/MILCOM.1996.568636
 - [12] LIU Z, HU X, XU L, et al. Low Computational Complexity Digital Predistortion Based on Convolutional Neural Network for Wideband Power Amplifiers [J]. in IEEE Transactions on Circuits and Systems II: Express Briefs, 2022, 69(3): 1702-1706, doi: 10.1109/TCSII.2021.3109973
- 作者简介: 舒海燕(1998-),女,汉族,安徽六安人,就读于宁波大学计算机工程学院,通信工程专业硕士,研究方向为数字预失真、深度学习。■